

中原大學

CHUNG YUAN CHRISTIAN UNIVERSITY

人工智慧實務

期末報告

中華民國台灣空氣品質預測模型

Taiwan(R.O.C.) Air Quality Prediction Model

資管四乙

潘聰杰

資訊碩專二

黎彥德

資訊碩一

張家睿

中華民國 115 年 1 月 7 日

目錄

壹、 資料處理與特徵工程	1
一、 原始資料說明	1
二、 資料清洗	1
三、 特徵工程	2
四、 訓練集與測試集切割	3
貳、 模型結果與解讀	4
一、 線性回歸結果解讀	4
(一)、 評估指標	4
(二)、 係數分析與特徵重要性	4
(三)、 預測分析	5
二、 決策樹結果解讀	7
(一)、 評估指標	7
(二)、 混淆矩陣分析	7
(三)、 決策規則解讀	8
(四)、 特徵重要性分析	9
(五)、 發現討論	10
三、 隨機森林結果解讀	10
(一)、 評估指標與 OOB Score	10
(二)、 混淆矩陣分析	11
(三)、 特徵重要性分析	12
(四)、 發現討論	12
四、 模型比較分析	13
參、 結論與建議	14

壹、 資料處理與特徵工程

一、 原始資料說明

本專案使用台灣環境保護署開放資料平台的空氣品質監測站數據，資料透過 API 下載後轉換格式，並儲存於專案資料庫。涵蓋 2016 年 11 月至 2024 年 8 月的歷史數據，由於 2016 年與 2024 年僅部分月份有數據，故我們未使用這兩年的數據。其中 2017 至 2022 年數據作為訓練集，共計約 149 萬筆資料；驗證集使用 2023 年上半年資料約 11.5 萬筆；測試集使用 2023 年下半年資料約 11.5 萬筆。採用多年訓練方案的目的是在於涵蓋完整的季節循環與年度變異。

在地區篩選方面，延續期中報告的研究設計，選取三個具代表性的縣市進行分析。新北市位於北部都會區，受東北季風調節影響顯著；彰化縣代表中部農工混合區域，具有獨特的污染型態；高雄市則為南部重工業區，污染源相對較多。三個縣市的空氣品質特性各異，能夠代表台灣不同區域的環境狀況，有助於建立具有廣泛適用性的預測模型。

資料集	時間範圍	樣本數
訓練集	2017-2022 年	1,492,716 筆
驗證集	2023 年上半年	114,978 筆
測試集	2023 年下半年	114,979 筆

表 1 資料集時間範圍與樣本數

二、 資料清洗

原始資料中存在兩類需要處理的無效數值。第一類是標準的 NaN 空值，這些資料直接予以移除。第二類是無效 AQI 值（值為 -1），同樣予以移除。經過初步清理後，訓練集從 160 萬餘筆減少至約 149 萬筆，清理比例約 7.10%；測試年資料從 24.6 萬筆減少至約 23 萬筆，清理比例約 8.12%。

此外部分污染物數據使用 -999，這是原始資料來源的特殊編碼方式，這裏的處理方式採用線性插值法填補，並設定最多連續填補 6 筆的限制。首先將 -999 轉換為 NaN，接著按縣市分組進行插值計算，並且透過分組處理可確保插值計算不會跨越不同縣市。

三、 特徵工程

本專案的特徵工程主要處理四個面向：滯後特徵設計、時間週期編碼、季節編碼改進、以及縣市編碼。最終模型使用的特徵包含 6 個污染物滯後特徵、1 個氣象特徵、4 個時間週期特徵、4 個季節指標、以及 1 至 3 個縣市指標，共計約 16 個特徵欄位。

為了以過去的污染物濃度預測當前時間的 AQI，本專案產生兩組滯後特徵：Lag-1 特徵記錄前一小時的 PM2.5、PM10 與 O₃ 濃度，用於捕捉短期趨勢與連續性；Lag-24 特徵記錄前 24 小時（即前一天同時刻）的污染物濃度，用於捕捉每日的週期模式。我們的滯後特徵設計彙整如下表：

特徵名稱	時間偏移	主要目的
Lag-1	前 1 小時	捕捉污染物的短期連續性與即時趨勢。
Lag-24	前 24 小時	捕捉每日規律的週期性（如交通尖峰影響）。

表 2 滯後特徵設計彙整

原始資料中的小時與月份欄位為整數編碼（如 hour = 0, 1, ..., 23），這種編碼方式可能影響模型學習其週期性。例如 23 點與 0 點在時間上非常接近，但數值相差 23，模型難以學習這種鄰近關係。此外，本專案也根據其餘類型採取不同的編碼策略，整理如下表：

特徵	編碼策略/轉換公式	說明與適用模型
小時 (Hour)	$\frac{\sin}{\cos\left(\frac{2\pi \cdot \text{hour}}{24}\right)}$	解決 23 點與 0 點不連續，使模型能學習時間的連續性。
月份 (Month)	$\frac{\sin}{\cos\left(\frac{2\pi \cdot \text{month}}{12}\right)}$	解決 12 月與 1 月不連續，正確反應月份的鄰近關係。
季節 (Season)	One-Hot Encoding	產生四個二元欄位（春、夏、秋、冬），避免模型誤認季節間存在順序關係。
縣市 (County)	One-Hot Encoding	用於線性迴歸。避免標籤編碼隱含的大小關係誤導模型預測。
縣市 (County)	標籤編碼 (Label Encoding)	用於決策樹與隨機森林。樹模型的分裂機制不受數值大小關係影響。

表 3 編碼方法整理

四、 訓練集與測試集切割

時間序列資料在切分訓練集與測試集時，必須遵循時間順序以避免未來資訊洩漏。本專案採用多年訓練方案：使用 2017 至 2022 年共六年的資料作為訓練集，涵蓋完整的季節循環與年度變異；使用 2023 年上半年資料作為驗證集，用於調整模型參數；使用 2023 年下半年資料作為測試集，評估模型的真實泛化能力。這種切分方式確保模型在訓練過程中不會接觸到任何 2023 年的資料，測試結果能夠真實反映模型對未來數據的預測表現。

在分類任務中，目標變數 AQI 等級依據環保署標準分為三類：良好（AQI 0-50）、普通（AQI 51-100）、對敏感族群不健康（AQI 101-150）。觀察訓練集的類別分佈，良好佔 49.3%、普通佔 39.2%、對敏感族群不健康佔 11.5%，分佈相對平衡。然而測試集呈現嚴重不平衡：良好佔 69.7%、普通佔 27.8%、對敏感族群不健康僅佔 2.6%，良好與不健康的比例達到 27:1。由於測試集存在嚴重的類別不平衡，分類模型在訓練時採用類別權重平衡策略，根據類別頻率的倒數自動調整權重，使少數類別在訓練過程中獲得更高的影響力，避免模型過度偏向多數類別而忽略少數但重要的空氣品質警示等級。

貳、模型結果與解讀

本章節呈現三個機器學習模型的訓練結果與解讀，包括線性回歸、決策樹與隨機森林。線性回歸用於預測連續的 AQI 數值，而決策樹與隨機森林則用於分類 AQI 等級。透過多模型比較，可以更全面地理解空氣品質預測的關鍵因素。

一、線性回歸結果解讀

線性回歸模型使用封閉形式解（最小平方方法）進行訓練，對所有數值特徵進行標準化處理，使各特徵的係數可以直接比較重要性。模型共使用 18 個特徵，包含污染物滯後特徵、氣象特徵、時間週期特徵與類別特徵。

(一)、評估指標

模型在測試集上達到 $R^2 = 0.70$ ，表示能夠解釋約 70% 的 AQI 變異量，屬於可接受的擬合程度。均方根誤差（RMSE）為 12.49，平均絕對誤差（MAE）為 9.06。模型在訓練集的 R^2 為 0.76，驗證集為 0.72，測試集略低於訓練集顯示輕微的過擬合，但差距在合理範圍內。

指標	訓練集	驗證集	測試集
R^2 (決定係數)	0.7596	0.7162	0.7012
RMSE (均方根誤差)	15.85	14.46	12.49
MAE (平均絕對誤差)	11.33	10.66	9.06

表 4 線性回歸模型評估指標

(二)、係數分析與特徵重要性

係數條形圖清楚呈現各特徵對 AQI 預測的影響程度與方向。橫軸表示標準化後的迴歸係數值，正值表示該特徵與 AQI 呈正相關，負值則為負相關。條形長度越長表示影響程度越大。




圖 1 線性回歸特徵係數條形圖

從係數條形圖可以清楚辨識出模型的主要發現。首先，PM2.5 滯後特徵佔據絕對主導地位：pm2.5_lag24 的係數為 +11.98，pm2.5_lag1 為 +10.18，這兩個特徵的係數遠大於其他所有特徵，形成明顯的「雙峰長尾」效應。這說明過去的 PM2.5 濃度是預測當前 AQI 最重要的因素，兩者合計貢獻超過 50% 的預測力，符合空氣污染的時間持續性特徵。

其次，正負係數的分佈不對稱。大部分特徵為正係數（14 個），僅少數為負係數（4 個）。負係數特徵包括 county_new_taipei (-0.92)、season_summer (-0.19)、county_changhua (-0.32) 與 season_winter (-0.47)，暗示新北市與彰化縣的 AQI 相對較低，而高雄市 (+1.13) 則較高。這與地理位置、工業分佈及氣候條件相符：高雄為重工業城市污染源較多，新北受東北季風調節擴散條件較佳。

在時間特徵方面，月份的餘弦編碼（month_cos = +2.72）顯示顯著的季節效應。餘弦函數在冬季（12 月至 1 月）達到最大值，正係數意味著冬季 AQI 傾向較高，這與冬季大氣穩定度高、境外污染物傳輸頻繁的現象吻合。

(三)、預測分析

預測值與實際值散點圖用於評估模型預測的準確性。橫軸為實際 AQI 值，縱軸為模型預測值，紅色虛線代表完美預測線。若所有點都落在這條線上，表示模型預測完全正確。




圖 2 線性回歸預測值與實際值散點圖

從散點圖可以辨識出幾項關鍵發現。第一，主要預測群集位於 AQI 40-70 區間，點密度最高，這反映資料集中大部分時段的空氣品質為「良好」至「普通」等級，模型在這個常見範圍表現最佳，預測值與實際值高度吻合。第二，當實際 AQI 超過 100 時，預測點明顯偏離紅線且向下分佈，形成「扇形擴散」型態，表示模型對高污染事件傾向低估。這可能是因為極端污染事件樣本較少（僅佔約 2.6%），模型缺乏足夠學習機會，且線性模型本身無法捕捉非線性的污染累積效應。第三，當實際 AQI 低於 30 時，預測點多位於紅線上方，表示模型略為高估最優良空氣品質。第四，整體分佈呈橢圓形沿紅線分佈， $R^2 = 0.70$ 意味著模型解釋了 70% 的 AQI 變異量，剩餘 30% 可能來自未納入的因素（如即時氣象變化、突發排放事件）或線性模型的本質限制。




圖 3 線性回歸殘差分佈直方圖

殘差分佈直方圖進一步驗證模型的統計假設。殘差呈現鐘形曲線以 0 為中心對稱分佈，符合線性回歸要求殘差為常態分佈的基本假設。殘差均值接近 0 表示模型沒有系統性偏差，既非一貫高估也非一貫低估。大部分殘差落在正負 25 的範圍內（約 2 個標準差），表示預測誤差在可接受範圍。然而，圖表兩端存在少量極端殘差超過正負 50，這些對應到模型嚴重誤判的案例，通常發生在突發污染事件。另外，右尾（正殘差）略長於左尾，暗示模型對高 AQI 的低估比對低 AQI 的高估更常見。

二、決策樹結果解讀

決策樹分類模型使用 Gini 不純度作為分裂準則，透過建立 IF-THEN-ELSE 規則樹來進行 AQI 等級分類。模型設定最大深度為 5，使用類別權重平衡(class_weight='balanced')處理不平衡資料。目標是將空氣品質分為三個等級：良好(AQI 0-50)、普通(AQI 51-100)、對敏感族群不健康 (AQI 大於 100)。

(一)、評估指標

模型在測試集達到 82.11% 的準確率，超過目標 75%。實際樹深度達到設定的最大值 5，產生 32 個葉節點。F1 Score (macro) 為 66.63%，反映在類別不平衡情況下的整體表現。

指標	訓練集	驗證集	測試集
Accuracy (準確率)	77.01%	76.15%	82.11%
F1 Score (macro)	73.95%	71.96%	66.63%

表 5 決策樹模型評估指標

(二)、混淆矩陣分析

混淆矩陣呈現預測結果與實際類別的對照關係。縱軸為實際的 AQI 等級，橫軸為模型預測的等級，對角線數值代表正確預測的數量。




圖 4 決策樹混淆矩陣

從混淆矩陣中發現。第一，「良好」類別預測表現最佳，共 80,032 筆樣本中正確預測 70,135 筆，召回率達 88%，這是因為「良好」佔測試集 70%，樣本充足使模型學習效果最好。第二，「普通」類別出現明顯的混淆現象：共 31,977 筆樣本中有 4,080 筆被誤判為「對敏感族群不健康」（過度警示），5,507 筆被誤判為「良好」（警示不足），反映普通類別位於兩端類別的過渡地帶，邊界較模糊而難以精確區分。第三，「對敏感族群不健康」類別雖僅佔測試集 2.6%（2,970 筆），但模型仍成功識別出 1,888 筆（召回率 64%），證明使用 `class_weight='balanced'` 的類別權重調整策略確實有效處理了嚴重的類別不平衡問題。第四，整體準確率 82% 顯示模型對空氣品質等級的預測具有實用價值。

(三)、決策規則解讀

決策樹圖呈現模型學習到的分類規則。根節點為第一個分割條件，對預測影響最大；葉節點為最終分類結果。節點顏色反映分類傾向：藍色代表良好，綠色或黃色代表普通，橘色或紅色代表對敏感族群不健康。




圖 5 決策樹視覺化

從決策樹視覺化可以觀察到幾項重要發現。第一，根節點條件為 $pm2.5_lag24$ 小於等於 16.94，這意味著前一天同時刻的 PM2.5 濃度是模型判斷空氣品質的首要依據，其重要性超過所有其他特徵。第二，決策樹自動學習到的 PM2.5 閾值與官方 AQI 標準高度吻合：樹學習到的閾值約 17 對應良好等級（官方標準為 PM2.5 小於等於 $15.4 \mu g/m^3$ ），閾值約 34 對應普通等級（官方標準為 PM2.5 小於等於 $35.4 \mu g/m^3$ ）。這說明決策樹在完全沒有預設規則的情況下，成功「重新發現」了 AQI 計算公式中的 PM2.5 分級邊界，驗證了模型學習的有效性。第三，規則呈現清晰的階層結構：高層節點處理主要分類（良好 vs 非良好），低層節點則細分邊界案例。第四，深度 5 的限制使樹產生 32 個葉節點，兼顧了預測能力與可解釋性。

(四)、特徵重要性分析

在特徵重要性方面， $pm2.5_lag24$ 佔絕對主導地位，貢獻 79.3% 的分類預測力。 $pm2.5_lag1$ 補充近期趨勢，貢獻 16.6%，兩者合計超過 95%。 O_3_lag24 有邊際影響 (3.0%)，而季節與時間特徵影響極小。值得注意的是，縣市特徵 ($county_encoded$) 的重要性為 0%，表示在控制 PM2.5 濃度後，地區差異對 AQI 等級幾乎無影響。

(五)、發現討論

模型結果證實 PM2.5 是決定 AQI 等級的核心。光是前一天和前一小時的 PM2.5 濃度，就能貢獻 95.9% 的分類預測力。有趣的是，pm2.5_lag24 的重要性 (79.3%) 遠超過 pm2.5_lag1 (16.6%)，表示空氣品質有強烈的「日週期慣性」——如果昨天此時污染嚴重，今天很可能也嚴重。

三、隨機森林結果解讀

隨機森林是一種集成學習演算法，透過建立多棵決策樹並綜合其預測結果來提高準確度與穩定性。本模型使用 100 棵決策樹，每棵樹的最大深度為 10，採用多數決投票機制決定輸出類別。

(一)、評估指標與 OOB Score

模型在測試集達到 84.70% 的準確率，達到目標（大於 80%）。OOB Score (Out-of-Bag Score) 為 79.36%，與驗證集準確率 (77.94%) 相近，顯示 OOB 是可靠的泛化能力估計。OOB Score 是隨機森林的獨特優勢，透過 Bootstrap 抽樣中未被抽中的樣本來評估模型效能，無需額外驗證集即可估計泛化能力。

指標	訓練集	驗證集	測試集
Accuracy	79.61%	77.94%	84.70%
F1 (Macro)	76.42%	73.94%	69.22%
OOB Score	79.36%	-	-

表 6 隨機森林模型評估指標

(二)、混淆矩陣分析




圖 6 隨機森林混淆矩陣

從隨機森林混淆矩陣可以辨識出幾項關鍵發現。第一，「良好」類別預測最準確，對角線上數值最大（73,149），佔該類實際樣本的 91.4%，相較決策樹的 88% 召回率有所提升。第二，「普通」類別存在混淆，實際為「普通」的樣本中有 19.0% 被誤判為「良好」，11.0% 被誤判為「對敏感族群不健康」，與決策樹的混淆模式相似，反映中間類別本身的分類難度。第三，「對敏感族群不健康」樣本稀少僅 2,970 筆，模型正確識別 62.5%（1,855 筆），略低於決策樹的 64%，但仍有 36.0% 被誤判為「普通」，顯示極端不平衡類別的挑戰依然存在。第四，值得注意的是「良好」幾乎不會被誤判為「對敏感族群不健康」（僅 121 筆），反之亦然（僅 45 筆），表示模型能正確區分極端類別，誤判僅發生在相鄰類別之間。

(三)、特徵重要性分析




圖 7 隨機森林特徵重要性條形圖

從特徵重要性條形圖可以辨識出幾項關鍵發現。第一，PM2.5 滯後特徵主導預測力，pm2.5_lag24 (33.1%) 與 pm2.5_lag1 (23.5%) 合計佔 56.6%，構成模型的核心預測基礎。第二，Lag-24 的重要性 (33.1%) 高於 Lag-1 (23.5%)，表示日週期模式比短期趨勢更具預測價值，與決策樹模型的發現一致。第三，PM10 貢獻次之，pm10_lag24 (14.6%) 與 pm10_lag1 (14.5%) 合計約 29%，PM2.5 與 PM10 合計貢獻約 85% 的預測力，印證 AQI 計算主要由懸浮微粒決定。第四，臭氧 (O_3 lag24 = 2.9%) 與時間特徵 (month_cos = 3.7%) 貢獻相對較低，風速 (windspeed) 僅佔 0.44%，在控制污染物濃度後，風速對 AQI 等級的獨立影響幾乎可以忽略。這與期中報告觀察到的「風速與 AQI 呈負相關」形成對比，暗示該相關性可能是偽相關——風速透過影響 PM2.5 濃度間接影響 AQI，而非直接影響。

(四)、發現討論

日週期模式的重要性在隨機森林模型中得到進一步驗證。Lag-24 特徵比 Lag-1 特徵更重要，空氣品質有 24 小時週期的特徵。因此，預測今天上午 8 點的 AQI 等級時，昨天上午 8 點的數據比今天上午 7 點的數據更有參考價值。這項發現對實務應用具有重要啟發：空氣品質預警系統應以日週期數據為基礎，而非僅依賴即時監測值。

四、 模型比較分析




圖 8 決策樹與隨機森林模型比較

從模型比較圖可見：

- 隨機森林在 Accuracy 與 F1 兩項指標上均優於決策樹。
- 隨機森林準確率（84.70%）相比決策樹（82.11%）提升 2.59 %，在 11.5 萬筆測試資料上意味著額外正確分類約 2,980 筆樣本。
- F1 Macro 同樣提升 2.59 %（從 66.63% 到 69.22%），顯示隨機森林在處理類別不平衡時的表現較好。

線性回歸模型 R^2 約 0.7 表示具備基本的預測能力。線性回歸的獨特優勢在於係數可直接量化解釋各特徵的影響，例如 `pm2.5_lag24` 每增加一個標準差，AQI 平均增加約 12 點。這種可解釋性在政策制定與公眾溝通場域特別有價值。

三個模型均一致指向相同結論：PM2.5 滯後特徵是預測 AQI 最重要的因素，貢獻 50% 至 96% 的預測力；日週期模式（Lag-24）比短期趨勢（Lag-1）更重要，反映空氣品質有 24 小時週期；而風速在控制污染物濃度後對 AQI 的獨立影響極小，與我們在期中報告預想的不同。

參、 結論與建議

本報告運用線性回歸、決策樹與隨機森林三種機器學習模型，針對台灣空氣品質進行預測分析。透過 2017 至 2022 年共六年的訓練資料，模型成功學習到空氣品質變化的關鍵模式，並在 2023 年下半年的測試資料上展現不錯的預測能力。

我們從中發現：PM2.5 濃度通常是決定 AQI 數值的關鍵，每日污染變化是有規律的，風速對 AQI 的影響有限。

不過本報告存在以下限制。首先，模型對高污染事件（AQI 超過 100）的預測能力較弱。其次，本報告僅使用三個縣市（新北、彰化、高雄）的資料，模型對其他地區的能力有待驗證。

我們的決策樹模型可作為簡易預警規則：若前一天同時刻 PM2.5 超過 $35\text{ }\mu\text{g}/\text{m}^3$ ，則今日空氣品質可能對敏感族群不健康。隨機森林模型達到 84.70% 的分類準確率。敏感族群可參考前一天同時刻的空氣品質，預判今日的戶外活動風險。若昨日上午空氣品質不佳，今日上午宜減少戶外劇烈運動。我們認為在實務上，這有助於決策者理解污染控制措施的預期效果。